

ملاحظات العرض — مناقشة مشروع التخرج

تحسين جودة الاسترجاع في أنظمة RAG العربية باستخدام Query Enhancement · محمد الحاج وعثمان بشير · إشراف د. تهناني عبدالله

النص النهائي · Osman 15-22 · Mohammed 1-14

Slide 1 · Title — 15s

السلام عليكم ورحمة الله وبركاته. حضورنا الكرام، الدكاترة الأعزاء.
أنا محمد الحاج، ومعاي زميلي عثمان بشير. أطروحتنا اليوم بعنوان:

Improving Arabic RAG Retrieval Quality with LLM-based Query Enhancement

— بإشراف الدكتورة تهناني عبدالله.

Say the title in English, as printed. Previously the script gave an Arabic rendering while the

slide showed English — you would have been reading one thing with another on screen.

Slide 2 · Agenda — 12s

ودي محاور العرض: نبدأ بال **introduction**، بعدها **المشكلة والسؤال البحثي**، ثم **الأهداف**،
بعدها ال **methodology** والشغل اللي عملناه، ثم **النتائج والمناقشة**، ونختم بال **conclusion****
والعمل المستقبلي**.

Six items, one breath. Do not elaborate on any of them — you are about to explain all six.

*Slide 3 · LLMs and their limitation — 30s *(kept full, no cut)

ال **Large Language Models** — زي ChatGPT و Claude و Gemini — بقت أدوات قوية جداً في توليد النصوص

والإجابة على الأسئلة.

لكن عندها **limitation** أساسي: ال memory بتاعتها **parametric** — المعرفة كلها مخزنة جوه ال weights ومجمدة عند لحظة التدريب. ولو الداتا اتغيرت أو كانت داتا خاصة، ال **retraining** مكلف جداً.

خلّونا نشوف مثال. لو سألنا الموديل: «**ما الشروط التي تسمح للطالب بتأجيل دراسته في جامعة الخرطوم؟**»

لوائح الجامعة ما موجودة في البيانات اللي اتدرب عليها. ومع ذلك **ما بيقول ليك «ما عارف»** — بيجاب.

وشوفوا الإجابة: مادة رقم ١٢، ولائحة سنة ١٩٩٨، ورسوم ٥٠٠ جنيه. **كل ده مُخلّق**. ما في مادة زي دي ولا رسوم زي دي. بس الإجابة مكتوبة بثقة وبصياغة سليمة. ودي ال **hallucination**.

*Slide 4 · RAG and the librarian — 13s *(compressed)

عشان كده ظهر ال **RAG**: بدل ما نعيد تدريب الموديل، بندّي ليهو **knowledge base** يفتّش فيها. زي المكتبة بالظبط — أمين المكتبة ما بيجاب من ذاكرتو، بيمشي يجيب الكتب، والإجابة بتتكتب منها.

The slide already shows all four scenes. Do not walk them one by one.

*Slide 5 · Retrieval is the bottleneck — 17s *(cut applied)

طبيب — لو حظينا لوائح الجامعة **جوه** ال RAG system، الإجابة بقت موجودة في ال corpus. ومع ذلك

ممکن النظام يرجع بـ passages غلط، فالإجابة تفضل غلط.

يعني ال **bottleneck** هنا، في ال **Information Retrieval**. ودي اللي دفعتنا ندرس ال techniques اللي بتحسّنو.

The fork diagram *is* the correct-versus-wrong sentence. Do not say it as well.

Slide 6 · Rich in English, unvalidated in Arabic — 25s

فمشينا لل literature. ولقينا إنو في اللغة الإنجليزية ده مجال **غني جداً ومدرّس كويس** — ال **Query Enhancement**: نصلّح ال query **قبل** ما توصل لل retriever، من غير ما نلمس ال retriever

ومن غير ما نعيد فهرسة ال corpus. عائلة كاملة من التقنيات — Query2Doc، HyDE، GRF. طبيب — ومشينا نشوف ال literature **العربي**. **ولا واحدة من التقنيات دي اتعملت ليها validation على العربي. ** ولا في حد أثبت إنها بتشتغل بموديلات صغيرة كفاية إنو مجموعة زينا تقدر تشغلها.

"Almost nothing" is gone from the slide and the script. It undercut you. The claim is now the

precise one Chapter 2 actually makes — *not one validated for Arabic* — which is stronger *and*

defensible, because the gap you are claiming is a validation gap, not an absence of all work.

*Slide 7 · But Arabic is not English — 10s *(cut applied)

والعربي عندو تحدياتو الخاصة: الاشتقاق، والإملاء، والتشكيل، والازدواجية اللغوية.
وزي ما شايفين في الأمثلة، كلها بتكسر المطابقة بين السؤال والدوكيومنت.

Name the four and stop. **Do not read** / **مكتوب** / **كاتب** / **كاتب** **aloud** — the panel are Arabic speakers

and they read the examples faster than you can say them.

Slide 8 · Research question — 20s

فال **research question** بتاعنا: **إلى أي مدى ال LLM-based Query Enhancement بتقدر تحسّن ال

Arabic Information Retrieval — عبر ال sparse وال dense وال hybrid — باستخدام موديلات مفتوحة من

2 ل 8 مليار باراميتريز؟**

وأبعد من ال validation — وده ال **contribution** الخاص بينا — دايرين نعرف: **كيف ال retrievers المختلفة بتتفاعل مع ال Query Enhancement؟**

Slide 9 · Objectives — 18s

وعشان نجابو على السؤال ده حدّدتنا تسعة **objectives**. باختصار شديد: نبني ال **baselines** ونحلّل فشلها، نكيّف ال **Query2Doc** للعربي ونقارن عشرة موديلات، ونشوف ال **sparse** وال **dense** بيتفاعلوا معاها كيف، ونعالج ال **term dilution**، ونبني **hybrid baseline**، ونطبّق ال **CSQE**، وأخيراً نحدّد المكان الأمثل لل expansion جوه ال pipeline. والتفاصيل قدامكم على الشاشة.

One breath, no pauses between items. The nine are printed in full — let them read.

Slide 10 · The system we built — 40s

وبدينا بأول objective: **تبنّي ال baseline**. ودي المنظومة اللي بنيناها.
ال **corpus** بتاعنا 2 — **MIRACL Arabic** مليون passage من ويكيبيديا العربية.
وال **retriever** — وهنا في نوعين. ال **BM25**، وده sparse، بيشتغل بال exact term matching.
وال **Dense**، وعندنا mDPR، بيحوّل ال query ل vector وبيفهم المعنى حتى لو الكلمات مختلفة.
وكل واحد فيهم بيفشل في نوع مختلف من الأسئلة — يعني هم complementary.
والقياس بتاعنا **NDCG@10**.

*Slide 11 · Baseline results — 30s *(cut applied)

وأول حاجة، **أعدنا إنتاج النتائج المنشورة بالضبط** — عشان أي تحسّن بعد داك يكون بسببنا إحنا.
ال **mDPR** جاب **0.4993**، وال **BM25** جاب **0.4621**.
بعدها عملنا **error analysis**. لقينا **34%** من الكويريز فاشلة تماماً. والأهم: ****الكويريز القصيرة**
أداءها أضعف بشكل واضح — **0.345**. **والسبب هو ال information poverty****.
يعني **العطل في ال query ذاتها**. وعشان كده اخترنا ال **Query Expansion** كـ QE technique بتاعتنا.
This is the only place the technique choice is stated. It used to be said here *and* on
slide 12 — the same justification twice, thirty seconds apart.

*Slide 12 · Query2Doc — 25s *(redundancy removed, figure and prompt added)

والفكرة في ال **Query2Doc** فيها حاجة ظريفة: كلنا عارفين إنو ال LLMs بتهلوس — لكن هنا ****الهلوسة**

مش مشكلة، هي ذاتها الحل ******.

بنطلب من الموديل يوّد **hypothetical document**. وده ال prompt الاستخدمناهو — بسيط جداً، **zero-shot**، من غير أي أمثلة.

المعلومات في النص ده ممكن تكون غلط تماماً — لكن ****** ال vocabulary بتاعو قريب من الدوكيومنتات

الحقيقية ******، فبتقرب المسافة اللغوية بين السؤال والإجابة.

Opens on the mechanism, not on the diagnosis. The UofK example is **gone from this slide** — it was

doing the same job twice and cluttering the layout. The Query2Doc figure and the real system prompt

now carry it.

*Slide 13 · Dense vs BM25 — 25s *(cut applied)

وعشان نتأكد إنو التقنية بتعمّم، عملنا **comparison** بين **عشرة موديلات**، من 2B ل 8B، بنفس البرومبت ونفس ال pipeline.

على ال **Dense**، الموديلات التسعة كلها اتحسنّت — أحسنها **Aya Expanse** بـ **+23.5%**.

لكن على ال **BM25**، **ستة من تسعة** بقى أداؤها **أسوأ** من ال baseline ذاتو.

نفس التقنية، نفس النص المود — **ونتيجتين في اتجاهين متعاكسين**.

They can see. Say the finding, not the «على اليمين» and «على اليسار» Cut «زي ما شايفين على اليسار» reading.

*Slide 14 · Query repetition — 23s *(cut applied, denser)

ولما فتننا في السبب لقينا هو الـ **term dilution**: لما تضيف تمانين كلمة مولدة على سؤال من أربع

كلمات، الكلمات الأصلية وزنها يضيع.

فمعالجتنا كانت الـ **query repetition** — نكرر الكويري الأصلية جوّه الكويري الموسّعة. وعملنا

sweep على معامل التكرار لكل موديل، والـ optimum طلع **بيختلف من موديل لموديل**.

والنتيجة: **كل الموديلات التسعة بقت فوق الـ baseline**، وأحسن نتيجة **Aya بـ 0.5855**.

The adaptive-versus-fixed detail and the $\beta=2 / n=5-10$ numbers are **Q&A material**. They are on

your sheet, not in the talk.

وهنا أسلّم الكلام لزميلي عثمان. اتفضل يا عثمان.

*Slide 15 · Where expansion breaks — 50s *(protected, no cut)

شكراً محمد. طيب عشان نشوف الـ **expansion** بيفشل وين، خدوا معاي المثال ده:

«ما هي الأسماء الخمسة في اللغة العربية؟» — دي قاعدة نحوية مشهورة، والإجابة **أب، أخ، حم، فو، ذو**.

والـ BM25 العادي، بالكويري الأصلية، لقي المقال الصح في **المرتبة الأولى** — بنتيجة **1.000**.

لكن لما ودّينا للموديل يعمل **expansion**، قال ليك بثقة: «فئة خاصة من الأسماء الأكثر شيوعاً:

محمد، آدم، إبراهيم، إسماعيل» — أسماء أشخاص!

فالأسماء المهلوسة دي اشتغلت كـ **noise** — ودّت البحث في اتجاه غلط تماماً. والمقال الصح ما فيهو ولا

واحدة من الكلمات دي. النتيجة نزلت من **1.000** لـ **0.000**.

ودي وصلّتنا للفكرة المفتاحية: الـ **expansion** **ما المفروض تعتمد على ذاكرة الموديل** — لازم تكون

grounded في الـ corpus ذاتو.

ودي فكرة ال **CSQE — Corpus-Steered Query Expansion**: **بدل ما الموديل يعتمد على ذاكرته، يجاوب من ال corpus**.

فبنبني الكويري النهائية من **ثلاثة components**:

أولاً — BM25 first pass بالكويري الأصلية، بنجيب **top-5 documents**، وبنقول للموديل: استخرج

الجمال المفتاحية من الدوكيومنتات دي. معلومات **موجودة فعلاً في ال corpus**، مش هلوسة.

vocabulary enrichment لل **blind expansions** **ثانياً** — بنضيف **اثنين**

وثالثاً — بنكرر الكويري الأصلية **أربع مرات**.

ونرجع لسؤالنا: ال first pass رجّع المقال الصح، وفيه **أب، أخ، حم، فو، ذو**. فال expansion هسي

شايلة الكلام الصح — **مش لأنو الموديل عرفو، لكن لأنو اتنسخ من دوكيومنت موجود**. النتيجة رجعت **1.000**.

وعلى كل ال dataset: ال BM25 مع CSQE قفز من **0.4621** ل **0.6157**.

*Slide 17 · The contribution — 62s *(cut applied)

طيب. ال BM25 وال Dense ييفشلوا في أسئلة مختلفة — فجربنا **ندمجهم** في نظام **hybrid**، من غير أي

enhancement. النتيجة **0.6267**.

وبعدين جينا ندمج ال **CSQE** مع ال hybrid. والسؤال: **منو فيهم ياخد الكويري الموسعة؟** جربنا التلاتة configurations.

لو أدّيت **اللاتين** — **0.6936**. لو أدّيت ال **Dense** بس — **0.6474**. لكن لو أدّيت ال **BM25**** بس، **وخلّيت ال Dense على الكويري الأصلية** — **0.7137****.

ودي المعمارية النهائية اللي على اليمين: الكويري الموسعة بتمشي لل BM25، والكويري الأصلية بتمشي

لل mDPR، واللاتين بيتدمجوا بال RRF.

نفس التقنية، نفس ال hybrid، نفس الموديل. **المتغيّر الوحيد منو استلم ال expansion.**

وليه؟ ال **hybrid** **بيستفيد من الاختلاف** بين الطريقتين. لو اللاتين شالوا نفس الكويري، بيتقاربوا — وال **complementarity** اللي دمجتا عشانها بتضيع.

فالمبدأ: **كل retriever محتاج ال query representation** **البتخصو**. وحسب مراجعتنا لليتريتشر، ال

asymmetric assignment ده ما اتدرس قبل كده.

*Slide 18 · The full journey — 40s *(kept, no cut)

دي **wrap-up** لل progression بتاع الإكسبيرمنتس، وبتوضّح **المنهجية العلمية** اللي كنا محافظين

عليها: بنحلّ ال current system عشان نحدّد ال weaknesses، ونبتكر ليها حل، ومن ثمّ **نقيس**

النتيجة، ونرجع ثاني من الأول — **loop مستمر** لحدي ما نصل لأحسن نتيجة ممكنة.

بدأنا بال **baseline**، وحلّلنا مشكلة ال **short queries**، وعملنا ليها **query expansion**.

ولما ظهرت مشكلة ال **term dilution**، حليناها بال **query repetition**. وواجهتنا مشكلة ال

hallucination، وحليناها بال **corpus-steered query expansion**.

والسيستم النهائي — **hybrid** بدمج **BM25** بال **Corpus-Steered Expansion** مع **Dense**** بالكويري

الأصلية — **أدّانا 0.7137: أحسن من ال baseline بـ 54.5%****، وتفوّق على ال hybrid اللي بدون

query expansion بـ 13.9%.

والأهم إنو ال **short queries** — اللي كانت أول مشكلة واجهتنا — لقيناها اتحسّنت بـ **43.6%.**

*Slide 19 · All four metrics — 10s *(kept; you were right, it is 10s not 30s)

وكل الأرقام اللي عرضناها كانت **NDCG@10** — لكن قسنا **أربع metrics**، والسيستم النهائي بتاعنا هو

الأعلى في الأربعة.

Say **"highest on all four"** — **not** **"the trend is consistent everywhere"**. At baseline BM25S

beats mDPR on Recall@100 (0.8577 vs 0.8407), and a clean-ordering claim contradicts that cell.

As a conclusion —

[Then the six, briskly. One breath, no elaboration between them:]

أسسنا ال **baselines** وحللناها ... قارنا عشرة موديلات مفتوحة ... لقينا ال **dense** وال **sparse** بيتفاعلوا مع ال QE بصورة مختلفة ... ال **query repetition** عالجت ال **degradation** في ال **sparse** ...

ودي الأهم — **retriever-specific query representation** اتأكد ... وال **corpus grounding** ال فيهم.

ودي مساهمتنا: إحنا شغالين في موضوع **حيّ جداً** هسي — ال RAG هو الطريقة اللي بتبني بيها أنظمة

ال LLM دلوقت، والعربي **مهمّش** فيه. فقدّمنا أول **validation منهجي** لل LLM-based query enhancement في ال Arabic IR، بعشرة موديلات مفتوحة، على hardware مجاني — يعني **قابل للتكرار** من

أي مجموعة بحثية عربية.

وأهم finding عندنا — ال **asymmetric placement** — إحنا قاعدين نكتب فيه ورقة علمية هسي.

The "not Arabic-specific / term dilution is a BM25 property" passage is **cut**, as you asked.

The

seven conclusions stay printed on the slide.

Slide 21 · Future work — 20s

للمستقبل، داير نغطّي ال **dialectal Arabic**، ونعمل **first-pass quality gate**، ونجرّب **embedding models** أقوى.

Slide 22 · Thanks — 10s

شكراً جزيلاً لحسن استماعكم — وجاهزين لأسئلتكم.

Moved to Q&A, not lost
