

ملاحظات العرض — مناقشة مشروع التخرج

تحسين جودة الاسترجاع في أنظمة RAG العربية باستخدام Query Enhancement · محمد الحاج وعثمان بشير · إشراف
د. تهناني عبدالله

محمد الحاج · Slides 1-14

Slide 1 · Title & greeting — 15s

السلام عليكم ورحمة الله وبركاته. حضورنا الكرام، الدكاترة الأعزاء.
أنا محمد الحاج، ومعاي زميلي عثمان بشير. أطروحتنا اليوم بعنوان: ****تحسين جودة ال Retrieval في أنظمة ال RAG العربية باستخدام ال LLM-based Query Enhancement**** — بإشراف الدكتورة تهناني عبدالله.

Slide 2 · Agenda — 10s

Content deferred until all slides exist.

Slide 3 · LLMs, their limitation, and our example — 30s

ال **Large Language Models** — زي ChatGPT و Claude و Gemini — بقت أدوات قوية جداً في توليد النصوص

والإجابة على الأسئلة.

لكن عندها **limitation** أساسي: ال memory بتاعتها **parametric** — المعرفة كلها مخزنة جوه ال weights ومجمدة عند لحظة التدريب. ولو الداتا اتغيرت أو كانت داتا خاصة، ال **retraining** مكلف جداً.

خلّونا نشوف مثال حيمشي معانا طول العرض:

«ما الشروط التي تسمح للطالب بتأجيل دراسته في جامعة الخرطوم؟»

لوائح الجامعة ما موجودة في البيانات اللي الموديل اتدرب عليها. ومع ذلك — ما بيقول ليك «ما عارف».

بيجاوب، بثقة، وبغلط. ودي ال **hallucination**.

Slide 4 · RAG and the librarian — 25s

عشان كده ظهر ال **RAG**. الفكرة: بدل ما نعيد تدريب الموديل، بندي ليهو **external knowledge base**

يقدر يفتش فيها.

خلّونا نتخيّل مكتبة. جاء زول وسأل. أمين المكتبة ما بيجاوب من ذاكرتو — بيمشي يختار الكتب المناسبة

ويجييها، والإجابة بتتكتب **من الكتب دي**.

ودي بالظبط ال RAG: ال query بتجي، النظام بيسترجع ال passages من ال corpus، وال LLM بيجاوب منها.

Slide 5 · Retrieval is the bottleneck — 25s

نرجع لسؤالنا. حطينا لوائح الجامعة **جوه** ال RAG system — يعني الإجابة موجودة في ال corpus حرفياً.

ومع ذلك النظام رجع ب passages غلط، لأنو الطريقة اللي الطالب بيسأل بيها مختلفة عن الطريقة اللي

اللائحة مكتوبة بيها. فالإجابة لسة غلط.

جودة الإجابة بتعتمد على الكتب اللي أمين المكتبة جابها. جاب الصح — الإجابة صح. جاب غلط — الإجابة

غلط والموديل بيهلوس.

يعني ال **bottleneck** هنا، في ال Information Retrieval. ودي اللي دفعتنا ندرس ال techniques اللي

بتحسّو.

Slide 6 · Query Enhancement — rich in English, empty in Arabic — 25s

فمشينا لل literature. ولقينا إنو في اللغة الإنجليزية ده مجال **غني جداً ومدرّوس كويس** — ال **Query Enhancement**: نصّلح ال query **قبل** ما توصل لل retriever، من غير ما نلمس ال retriever ومن غير ما نعيد فهرسة ال corpus. عائلة كاملة من التقنيات — Query2Doc، HyDE، GRF. طيب — ومشينا نشوف ال literature **العربي**... ولقينا هو **ضعيف جداً**. ما في حد أثبت هل التقنيات دي

بتنتقل للعربي، ولا هل بتشتغل بموديلات صغيرة كفاية إنو مجموعة زينا تقدر تشغلها.

Slide 7 · But Arabic is not English — 20s

طيب — هل العربي زي الإنجليزي؟ إحنا ما عارفين إذا الحاجات دي حتنطبق بنفس الصورة ولا لأ. لأنو العربي عندو تحدياتو الخاصة:

ال root-and-pattern — morphology، الجذر الواحد بيطلع منو عشرات الصيغ.

وال orthography — الهمزة والألف، التاء المربوطة والهاء.

وال diglossia — الناس بتسأل بالعامية، والمعرفة مكتوبة بالفصحى.

Slide 8 · Research question — 20s

condensed to one — the problem statement is already delivered by slides 6 and 7

فال **research question** بتاعنا: **إلى أي مدى ال LLM-based Query Enhancement بتقدر تحسّن ال

Arabic Information Retrieval — عبر ال sparse وال dense وال hybrid — باستخدام موديلات مفتوحة من

2 ل 8 مليار باراميتريز؟**

وأبعد من ال validation — وده ال **contribution** الخاص بينا — دايرين نعرف: **كيف ال retrievers المختلفة بتتفاعل مع ال Query Enhancement؟**

Slide 9 · Objectives — 20s

وعشان نجابو على السؤال ده، حدّدتنا تسعة **objectives**.

Figure 3.1 restyled, without the QE layer — one diagram, each component labelled with what we used

وبدينا بأول objective: **بنبي ال baseline**.

ودي المنظومة اللي بنيناها — **نفس الكومبوننتس** اللي شفناها في الأول، لكن هسي مليانة بالتفاصيل بتاعتنا.

ال **corpus** بتاعنا 2 — **MIRACL Arabic** مليون passage من ويكيبيديا العربية.
وال **retriever** — وهنا في نوعين. ال **BM25**، وده sparse، بيشتغل بال exact term matching.
وال **Dense**، وعندنا mDPR، بيحوّل ال query ل vector وبيفهم المعنى حتى لو الكلمات مختلفة.
وكل واحد فيهم بيفشل في نوع مختلف من الأسئلة — يعني هم complementary.
والقياس بتاعنا **NDCG@10**.

The queries count and the human-judgments line stay on the slide and out of your mouth, as you

asked. The panel reads them while you talk about the retrievers.

/ deletions applied: "matched the official number exactly", "96% of the official", the 1-in-10

وأول حاجة عملناها: **أعدنا إنتاج النتائج المنشورة بالضبط** — عشان نتأكد إنو ال pipeline بتاعنا صاح، وإنو أي تحسن بعد داك يكون بسببنا إحنا، مش بسبب اختلاف في ال setup. ال **mDPR** جاب **0.4993**، وال **BM25** جاب **0.4621**.

وقبل ما نختار تقنية، عملنا **error analysis** على ال baseline. لقينا **34%** من الكويريز فاشلة تماماً. والأهم: **الكويريز القصيرة أداها أضعف بشكل واضح — 0.345**. والسبب هو ال **information poverty**: كلمتين ما بيدّوا ال retriever معلومات كافية وسط 2 مليون passage. يعني **العطل في ال query ذاتها**. والتشخيص ده هو اللي حدّد لنا التقنية. لو المشكلة إنو السؤال فقير في المعلومات، فالحل لازم **يزوّد** السؤال معلومات — قبل ما يوصل لل retriever. وعشان كده اخترنا ال **Query Expansion** كـ QE technique بتاعتنا: من كل العائلة اللي شفناها في ال taxonomy، دي هي اللي بتعالج المشكلة اللي قسناها بالضبط.

The reproduction claim is back in, as you asked — and it does real work here: it is the answer

to **"how do we know your implementation is correct?"**, delivered before anyone asks it.

Keep the

precise figures on your Q&A sheet: mDPR matched the published MIRACL value exactly, BM25S reached

96% of Pyserini, the 4% gap being BM25S vs Pyserini's Java implementation.

the QE layer enters the diagram · constraint sentence deleted

بناءً على التحليل ده، دخلنا في السستم **layer** جديدة: ال **Query Enhancement**، وركّزنا على تقنية

Query2Doc.

وهنا في نقطة جميلة: كلنا عارفين إنو ال LLMs بتعاني من الهلوسة — لكن في التقنية دي،
**الهلوسة ما

مشكلة، هي ذاتها الحل. **بنطلب من الموديل يولّد** hypothetical document **. المعلومات فيهو
ممکن تكون

غلط، لكن الستايل وال vocabulary قريبة من الدوكيومنتات الحقيقية — فبتقرب المسافة اللغوية.

ونرجع لمثالنا: الكويري بقت تحمل ال vocabulary بتاع اللائحة نفسها — فال passage الصح رجع.

⚠ The regulation wording above is **plausible administrative Arabic that I wrote**, not
quoted from

the real UofK regulations. Either check it against the actual text or keep it generic — and
assert

no durations, numbers, or conditions. «تأجيل الدراسة» vs «إيقاف القيد» is the right kind of
mismatch for this panel, but do not present the sentence as a real quotation.

وعشان نتأكد إنو التقنية دي بتعمّم — يعني مش مرتبطة بموديل واحد بعينو — عملنا **comparison** بين

عشرة موديلات، من 2B لـ 8B، بنفس البرومبت ونفس ال pipeline.

على ال **Dense** — زي ما شايفين على اليسار — كل الموديلات التسعة اتحسنّت فوق ال baseline. أحسنها

Aya Expansive 23.5+ %.

لكن على ال **BM25** — على اليمين — ستة من تسعة بقى أداؤها أسوأ من ال baseline ذاتو.

نفس التقنية، نفس النص المولّد، **retriever** اتنين — ونتيجتين في اتجاهين متعاكسين.

⚠ **Do not let the image model draw these charts.** It will invent bar heights that look plausible

and are wrong. Composite the two real PNGs into the generated slide, or generate the slide with

empty chart areas and drop the PNGs in afterwards.

ولما فتّشنا في السبب لقينا هو الـ **term dilution**: الـ BM25 يحسب بالـ term overlap، فلما تضيف ثمانين كلمة مولّدة على سؤال من أربع كلمات، الكلمات الأصلية — اللي حاملة المعنى — وزنها بيضيع.

فمعالجتنا للمشكلة دي كانت الـ **query repetition**: نكرّر السؤال الأصلي جوّه الكويري الموسّعة عشان

نرجّع ليهو وزنو في المعادلة.

وما وقفنا عند كده — عملنا **sweep** على معامل التكرار لكل موديل من التسعة. ولقينا إنو ال optimum

بيختلف من موديل لموديل: أقوى موديلين عربياً وصلوا لأحسن أداء بالـ **adaptive repetition**، والباقي بقيمة ثابتة بين خمسة وعشرة.

والنتيجة: **كل الموديلات التسعة بقت فوق الـ baseline**. وأحسن نتيجة **Aya بـ 0.5855**.

"**is gone**, and the repetition sweep is in instead. That sweep *is* objective
6 —

nine models, each with its own optimum, adaptive vs fixed — and stating it is the difference

between a trick you tried and a result you established. Never describe your own finding as simple;

the panel will take the description at face value.

وهنا أسلّم الكلام لزميلي عثمان. اتفضل يا عثمان.

شكراً محمد. طيب عشان نشوف ال **expansion** بيفشل وين، خدوا معاي المثال ده: «ما هي الأسماء الخمسة في اللغة العربية؟» — دي قاعدة نحوية مشهورة، والإجابة أب، أخ، حم، فو، ذو.

وال BM25 العادي، بالكويري الأصلية، لقي المقال الصح في **المرتبة الأولى** — بنتيجة **1.000**. لكن لما ودينا للموديل يعمل **expansion**، قال ليك بثقة: «فئة خاصة من الأسماء الأكثر شيوعاً: محمد، آدم، إبراهيم، إسماعيل» — أسماء أشخاص!

فالأسماء المهلوسة دي اشتغلت ك **noise** — ودّت البحث في اتجاه غلط تماماً، ناحية مقالات عن رجال

اسمهم محمد وآدم. والمقال الصح، بتاع النحو، ما فيهو ولا واحدة من الكلمات دي. النتيجة نزلت من **1.000** ل **0.000**.

ودي وصلّتنا للفكرة المفتاحية: ال **expansion** **ما المفروض تعتمد على ذاكرة الموديل** — لازم تكون **grounded** في ال corpus ذاتو.

"Term dilution" is gone, as you asked — you already told the panel you solved that with query

repetition, so re-raising it here would read as the fix not working. **Noise pulling the search in

the wrong direction** is the right description and it is a different mechanism: dilution is about

the original terms losing *weight*, this is about generated terms actively pointing *elsewhere*.

"Blind" is gone too, and the closing line now reads *"expansion must not rely on the model's

memory — it must be grounded in the corpus"*. That is better than the earlier version: you have

never used the word "blind" with this panel, so introducing it here as a label for what you did

would land as jargon. Ending on **memory vs corpus** also hands straight into slide 16's new opening line.

Do not put the corpus-grounded answer on this slide. It is slide 16's reveal.

Slide 16 · CSQE — 45s

ودي فكرة ال **CSQE — Corpus-Steered Query Expansion**: **بدل ما الموديل يعتمد على ذاكرته، يجاوب من ال corpus**.

فبنبني الكويري النهائية من **ثلاثة components**:

أولاً — BM25 first pass بالكويري الأصلية، بنجيب **top-5 documents**، وبنقول للموديل: استخرج الجمل المفتاحية من الدوكيومنتات دي. يعني معلومات **موجودة فعلاً في ال corpus**، مش هلوسة. vocabulary enrichment لل **blind expansions** ثانياً — بنضيف **اثنين**

وثالثاً — بنكرّر الكويري الأصلية **أربع مرات**.

ونرجع لسؤالنا: ال first pass رجّع المقال الصح، وفيهو أب، أخ، حم، فو، ذو. فال expansion هسي شايلة الكلام الصح — **مش لأنو الموديل عرفو، لكن لأنو اتنسخ من دوكيومنت موجود**. النتيجة رجعت **1.000**.

والنتيجة على كل ال dataset: ال BM25 مع CSQE قفز من **0.4621** لـ **0.6157**.

Ablation dropped from the talk, as you asked. Keep 0.5381 / 0.5752 / 0.6157 on a backup slide —

"why not corpus-only?" is a likely question and it has a one-line answer.

طيب. ال BM25 وال Dense ييفشلوا في أسئلة مختلفة — فجربنا **ندمجهم** في نظام **hybrid**، من غير أي enhancement. النتيجة **0.6267**.

وبعدين جينا ندمج ال **CSQE** مع ال hybrid. والسؤال هنا: **منو فيهم ياخد الكويري الموسعة؟** جربنا التلاتة configurations.

لو أدّيت **اللاتين** — بتجيب **0.6936**.

لو أدّيت ال **Dense** بس — **0.6474**.

لكن لو أدّيت ال **BM25 بس**، وخليت ال Dense على الكويري الأصلية — بتجيب **0.7137**.

نفس التقنية، نفس ال hybrid، نفس الموديل. **المتغير الوحيد منو استلم ال expansion.**

وليه؟ ال **hybrid** **بيستفيد من الاختلاف** بين الطريقتين — قيمتهم كلها إنهم ييفشلوا في أسئلة مختلفة.

لو اللاتين شالوا نفس الكويري الموسعة، بيتقاربوا، ويبعدوا يرجعوا نفس الدوكيومنتات ويغلطوا نفس الغلطات — وال **complementarity** اللي دمجنا عشانها بتضيع.

فالمبدأ: **كل retriever محتاج ال query representation البتخصو.**

وحسب مراجعتنا للتريتشر — ال **asymmetric assignment** لل expansion عبر أنواع مختلفة من ال retrievers جوه hybrid dense-sparse، ده **ما اتدرس قبل كده.**

Changes applied. «خلينا نحدد البار الصح» is gone — you now just state the hybrid result.

«الحقيقية baseline ودي بقت ال» is gone, since it retroactively demoted every comparison made

before it. **RRF** → **hybrid** throughout. The Query2Doc callback is out. The Exp4Fuse sentence is out.

The OOD explanation is also out — "mDPR is trained on short queries so expanded queries are

out-of-distribution" is not tested anywhere in the thesis, and "did you measure that?" has no

good answer. The complementarity explanation is the one Chapter 5 actually supports.

⚠️ **Exp4Fuse must stay on your Q&A sheet.** The spoken claim is now narrow enough to match

chapter2.tex:410 — *asymmetric assignment across retriever types in a dense-sparse hybrid* — so

it is defensible as stated. But your own §2.5.4 cites Exp4Fuse (Liu et al., ACL 2025 Findings) as

the closest prior art. If anyone asks *"is this actually new?"*, name it yourself and then give the

narrow claim. Being shown your own citation is much worse than volunteering it.

Slide 18 · The full journey — 40s

your new draft — kept in your wording

دي **wrap-up** لل progression بتاع الإكسبيرمنتس اللي اشتغلناها، وبتوضّح **المنهجية العلمية** اللي كنا محافظين عليها طول التجارب: إننا **بنحلّ ال current system** عشان نحدّد ال weaknesses، ونبتكر ليها حل، ومن ثمّ **نقيس** النتيجة، ونرجع ثاني من الأول — ونتابع كده في **loop مستمر** لحدي ما نصل لأحسن نتيجة ممكنة.

بدأنا بال **baseline**، وحلّلنا مشكلة ال **short queries**، وعملنا ليها **query expansion**.

ولما ظهرت ليّنا مشكلة ال **term dilution**، حلّيناها بال **query repetition**. وكمان واجهتنا مشكلة ال **corpus-steered query expansion** وحلّيناها بال **hallucination**.

والسيستم النهائي بتاعنا — **hybrid**، بيدمج **BM25** بال **Corpus-Steered Expansion** مع **Dense****

بالكويري الأصلية من غير expansion — أدّانا 0.7137: أحسن من ال **baseline** بـ 54.5%،

وتفوّق على ال hybrid اللي بدون query expansion بـ 13.9%.

والأهمّ إنو ال **short queries** — اللي كانت أول مشكلة واجهتنا — لقيناها اتحسنّت بـ 43.6%.

Slide 19 · The same trend across all four metrics — 30s

كل الأرقام اللي عرضناها كانت **NDCG@10** — لكن إحنا قسنا أربع **metrics** في كل تجربة، ****وال** trend كان واضح في كلها. **والسيستم النهائي بتاعنا هو الأعلى في الأربعة****.

⚠️ **Say "our final system is highest on all four" — not "the trend is monotonic".** At baseline,

BM25S beats mDPR on Recall@100 (0.8577 vs 0.8407). That is the complementarity you already

explained, but if you claim a clean ordering everywhere, that one cell contradicts you.

As a conclusion —

ال **Query Enhancement** ينتقل للعربي بنجاح. لكن الأهم من كده: ال findings اللي طلعتنا بيها
 ما كانت خاصة باللغة العربية — دي خصائص عامة في طريقة تفاعل ال expansion مع ال
 retrievers.

ال **term dilution** خاصية في معادلة ال BM25 نفسها، مش في العربي. وال **complementarity collapse**

خاصية في ال fusion، مش في العربي. إحنا اكتشفناهم في العربي — لكنهم بينطبقوا على أي
 hybrid

retrieval system.

:Then the six, briskly — a beat each, no elaboration

أسسنا ال **baselines** وحللناها ... قارنّا عشرة موديلات مفتوحة ... لقينا ال dense** وال sparse
 بيتفاعلوا مع ال QE بصورة مختلفة ... ال query repetition** عالجت ال degradation في ال sparse
 ...

ودي الأهم — **retriever-specific query representation** اتأكد ... وال **corpus grounding** ال
 فيهم.

ودي مساهمتنا: إحنا شغالين في موضوع حيّ جداً هسي — ال RAG هو الطريقة اللي بتبني بيها
 أنظمة

ال LLM دلوقتي، والعربي مهمّش فيهو. فقدّمنا أول **validation منهجي** لل LLM-based query
 enhancement في ال Arabic IR، بعشرة موديلات مفتوحة، على hardware مجاني — يعني قابل
 للتكرار من

أي مجموعة بحثية عربية.

وأهم finding عندنا — ال **asymmetric placement** — إحنا قاعدين نكتب فيهو ورقة علمية هسي.

Changes applied. «ال findings» → «ال findings الثلاثة». "As a conclusion" → «نجي للخلاصة»
 since the count was wrong. «أهدافنا الثلاثة اتحققت» deleted. The complementarity/ablation
 row is

deleted entirely — slide and script both — so nothing on this slide contradicts dropping the ablation earlier.

The reframing holds up. The **mechanisms** are general (term dilution is a BM25 scoring property; complementarity collapse is a fusion property), while the **validation** was Arabic-only.

Phrased that way, *"did you test other languages?"* has an honest answer — no, and the wording already concedes it.

Slide 21 · Future work — 20s

للمستقبل، دایر نغظی ال **dialectal Arabic**، ونعمل **first-pass quality gate**، ونجرب **embedding models** أقوى.

Slide 22 · Thanks & questions — 10s

شكراً جزيلاً لحسن استماعكم — وجاهزين لأسئلتكم.